

Теория ошибок и ML: одна общая схема

Короткий вывод: внизу почти всегда лежит не “абсолютное знание”, а модель, договорённость и эвристика. Дальше строится инструмент, оценка, интервал и округление.

1. Общая лестница



Figure 1: Общая лестница и эталонный контур

Смысл схемы: мы не получаем истину напрямую, а строим всё более полезные приближения.

2. Где здесь эвристика



Figure 2: Эталон, калибровка и практическая польза

Эталон тоже не возникает из ничего: его получают через отдельную процедуру. Калибровка здесь означает сравнение прибора или метода с опорным образцом, чтобы получить поправку или шкалу пересчёта. “Опорный образец” — это объект или величина, которую в рамках конкретной методики уже

заранее закрепили как точку сравнения. Кто её закрепит? Тот, кто утверждает саму методику: лаборатория, метрологическая служба, производитель прибора, стандарт организации или государственный стандарт. По какому критерию? По заранее описанной процедуре: либо образец сравнили с более высоким эталоном, либо его стабильность и повторяемость проверили на контрольной серии, либо он задан как норматив внутри утверждённого протокола. Серия контрольных измерений — это повторные измерения на этом же образце, чтобы проверить, держится ли поправка и не поплыл ли разброс. После этого эталон используют как точку отсчёта только внутри той процедуры, для которой он был определён.

И здесь важно главное: в конечном итоге эталон, калибровка и контрольные измерения держатся не на каком-то мистическом абсолюте, а на согласованной процедуре, принятом стандарте и проверяемой практике. То есть фундамент здесь не в “чистом знании мира”, а в договорённости о том, как именно сравнивать, как считать и как проверять, что этот способ работает достаточно устойчиво. Поэтому вся цепочка измерения и оценки — это не доступ к абсолютной истине, а рабочая эвристика, которая подтверждается тем, что она стабильно даёт полезный результат.

Под “полезным результатом” здесь понимается не абстрактная правильность, а то, что метод даёт устойчивый и предсказуемый эффект в своей области: прибор не уходит из допуска, калибровка воспроизводится, самолёт держится в воздухе, а в ML качество модели остаётся выше базового уровня и не разваливается от фолда к фолду.

3. Теория ошибок в короткой цепочке

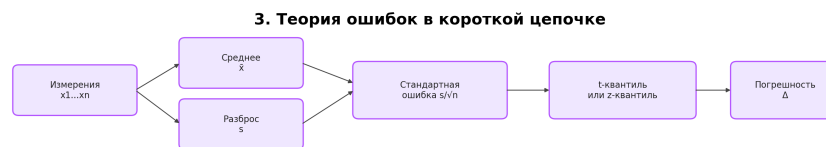


Figure 3: Теория ошибок в короткой цепочке

Формально:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\Delta = t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}}$$

Итоговая запись:

$$\bar{x} \pm \Delta$$

4. Почему появляется Student t



Figure 4: Почему появляется Student t

Если σ неизвестна, мы подставляем её оценку s . Тогда сам знаменатель становится случайным, и нужно учитывать эту дополнительную неопределённость. Поэтому интервал шире, чем при известной σ .

5. Что такое α

- $p = 0.95$ означает 95% доверия.
- Тогда $\alpha = 0.05$.
- Для двустороннего интервала по $\alpha/2$ остаётся в каждом хвосте.

Альфа — это уровень значимости: доля случаев, когда истинное значение не попадёт в интервал. Если доверие 95%, то $\alpha = 0.05$, то есть 5% остаются как допустимый риск промаха. Именно

5. Что такое α




Figure 5: Что такое α




Figure 6: Кривая распределения и центральная часть p

поэтому для двустороннего интервала по 2.5% уходит в каждый хвост распределения.

Квантиль — это граница, которая отделяет центральную часть распределения от хвоста. Например, $t_{0.975}$ означает точку, левее которой лежит 97.5% массы распределения, а в правом хвосте остаётся 2.5%. Если говорить совсем грубо, квантиль — это точка отсечения: левее неё лежит заданная доля массы распределения, а правее — оставшийся хвост.

6. ML-аналоги

6. ML-аналоги




Figure 7: ML-аналоги

В ML мы обычно не повторяем физический эксперимент, а повторяем оценку модели:

- разные фолды;
- разные seed;
- bootstrap;
- разные подвыборки;
- иногда разные конфигурации препроцессинга.

Это и есть практический аналог “много раз повторить одинаковый эксперимент”.

7. Что делать, если говорят “хочу точность не хуже ...”

7. Если цель: «точность не хуже ...»




Figure 8: Если цель: точность не хуже

Практический ответ в ML обычно такой:

1. Считаем mean и std по фолдам.
2. Строим доверительный интервал или нижнюю границу.
3. Проверяем, выше ли нижняя граница целевого порога.
4. Если нет, меняем данные, фичи, модель или число наблюдений.

8. Самый важный философский слой

На самом фундаменте почти всегда лежит не “чистая истина”, а рабочая схема:

- мы выбираем модель;
- калибруем инструмент;
- принимаем соглашения о том, как считать;
- оцениваем неопределённость;
- используем это, потому что система стабильно работает.

Именно поэтому самолёты летают: не потому, что мы всё знаем абсолютно, а потому что цепочка моделей, измерений,

8. Самый важный философский слой




Figure 9: Самый важный философский слой

допущений и проверок достаточно хороша. В этом смысле математика и статистика в прикладных задачах не открывают “абсолютную сущность мира”, а дают согласованный язык, на котором можно договориться о правилах сравнения и получить устойчиво работающий результат.

9. Короткая формула для памяти




Figure 10: Короткая формула для памяти

Если совсем коротко:

- истина недоступна напрямую;
- доступна только её оценка;
- в ML это не одноразовая стрелка, а цикл: данные -> модель -> оценка -> уточнение -> снова данные;
- качество оценки зависит от модели и инструмента;
- доверительный интервал описывает, насколько этой оценке можно верить;
- округление следует за неопределённостью, а не наоборот.

Важно: схема не про хронологию, а про зависимость шагов друг от друга. Данные нужны для построения модели, а модель нужна для того, чтобы извлечь из данных оценку и проверить, хватает ли этой оценки для решения.